

Algoritmizace

Rozděl a panuj



Rozděl a panuj / Divide et impera

Dekompozice: Rozděl problém na podproblémy

Rekurzivně najdi řešení podproblémů

Syntéza: Z řešení podproblémů sestroj řešení
původního problému

☀ **Příklady**

- Hanojská věž
- vyhodnocení aritmet. výrazu (v infixové notaci)
- třídění sléváním MergeSort
- třídění rozdělováním QuickSort

Třídění sléváním – MergeSort

Báze: Pole délky $n \leq 1$ je již setříděno

Dekompozice: Pole délky $n \geq 2$ rozděl na poloviny

Rekurzivně setříd' obě části


Syntéza: Obě setříděné části slej (**merge**) do jednoho setříděného pole

Jak sloučíme dvě setříděná pole?

Pozorování

- dvě setříděná pole lze sloučit do jednoho výsledného setříděného pole v lineárním čase
- = operace **slévání** (merge)

Příklad



MergeSort – dekompozice & rekurze

```
def mergeSort(a):  
    if len(a) > 1:  
        stred = len(a)//2 # stred pole  
        # kopie první a druhé poloviny  
        levy, pravy = a[:stred], a[stred:]  
        # obě poloviny setřídíme  
        mergeSort(levy)  
        mergeSort(pravy)  
        # indexy polí levy, pravy, a  
        i = j = k = 0
```

MergeSort – slévání

```
# slejeme setříděné části
# levy[] a pravy[] do pole a[]
while i < len(levy) and j < len(pravy):
    if levy[i] < pravy[j]:
        a[k] = levy[i]
        i += 1
    else:
        a[k] = pravy[j]
        j += 1
    k += 1
```

MergeSort – slévání – závěr

```
# na konec připojíme zbylé prvky  
# z levé či pravé části
```

```
while i < len(levy):
```

```
    a[k] = levy[i]
```


```
    i, k = i+1, k+1
```

```
while j < len(pravy):
```

```
    a[k] = pravy[j]
```

```
    j, k = j+1, k+1
```

MergeSort – průběh výpočtu



- ☀ výpočet – průchod stromem rekurze do hloubky
- ☀ zásobník dosud nezpracovaných podúloh

Strom rekurze

Vrcholy

- podúlohy (rekurzivně) volané během (rekurzivního) algoritmu

Kořen

- původní úloha

Děti každého rodiče

- představují podúlohy, (rekurzivně) volané v rodičovské úloze

Strom rekurze

hladina

čas

0


$O(n)$

1

$O(n)$


2

$O(n)$



.....

$\lceil \log_2 n \rceil$



$O(n)$

Časová složitost

- $T(n) = \lceil \log_2 n \rceil \cdot O(n) = O(n \log n)$

MergeSort – prostorová složitost

Prostor

- pracovní paměť: **pomocné pole** pro slévání
- **zásobník** pro obsluhu rekurze

Odvození velikosti pracovní paměti pomocí stromu rekurze

- vrchol stromu \rightarrow úsek délky $k \rightarrow$ prostor $\Theta(k)$
- v paměti je vždy právě zpracovávaný vrchol
- + všichni jeho předchůdci
- nejhorší případ: pracovní paměť pro všechny podúlohy (vrcholy) na cestě z kořene do listu

MergeSort – prostorová složitost

Necht' $n = 2^k$. Pak pracovní paměť

$$S(n) = O(n) + O(n/2) + O(n/4) + \dots + O(1) = O(n)$$

Necht' $2^k < n < 2^{k+1}$.

- položíme $n^* = 2^{k+1}$
- pak $n^* < 2 \cdot n$

$$\begin{aligned} S(n) &\leq O(n^*) + O(n^*/2) + O(n^*/4) + \dots + O(1) \\ &\leq c \cdot n^* < c \cdot 2 \cdot n = O(n) \end{aligned}$$

Složitost – alternativní odvození

Časovou i prostorovou složitost vyjádříme
rekurentním vztahem

$$T(1) = O(1), T(n) = 2 \cdot T(n/2) + O(n)$$

$$S(1) = O(1), S(n) = S(n/2) + O(n)$$

Řešení

- postupné dosazování
- hypotéza o přesném řešení
- důkaz matematickou indukcí

MergeSort bez rekurze

☀ Idea

- **běh** – souvislý setříděný úsek pole
- začneme s 1prvkovými běhy vstupního pole
- poté budeme slévat vždy dva sousední běhy do jediného běhu o dvojnásobné délce
- v poslední iteraci bude pole obsahovat jediný běh

Časová složitost $O(n \log n)$

- jako rekurzivní MergeSort

Prostorová složitost $O(n)$

- potřebujeme pomocné pole, do něhož sléváme cílové běhy ze zdrojových běhů v poli původním

Nerekurzivní MergeSort – čas

délka běhu

čas

1	<table><tr><td>8</td><td>2</td><td>6</td><td>4</td><td>1</td><td>3</td><td>9</td><td>5</td></tr></table>	8	2	6	4	1	3	9	5	$O(n)$
8	2	6	4	1	3	9	5			

2	<table><tr><td>2</td><td>8</td><td>4</td><td>6</td><td>1</td><td>3</td><td>5</td><td>9</td></tr></table>	2	8	4	6	1	3	5	9	$O(n)$
2	8	4	6	1	3	5	9			

4	<table><tr><td>2</td><td>4</td><td>6</td><td>8</td></tr></table>	2	4	6	8	<table><tr><td>1</td><td>3</td><td>5</td><td>9</td></tr></table>	1	3	5	9	$O(n)$
2	4	6	8								
1	3	5	9								

.....

2^k

$O(n)$

$$2^k < n \implies k < \log_2 n \leq \lceil \log_2 n \rceil \implies k + 1 \leq \lceil \log_2 n \rceil$$

Časová složitost

- $T(n) = \lceil \log_2 n \rceil \cdot O(n) = O(n \log n)$

MergeSort – slévání

```
def merge(a,temp,zacatek,stred,konec):  
    i,j,k = zacatek,stred+1,zacatek  
    while i <= stred and j <= konec:  
        if a[i] < a[j]:  
            temp[k] = a[i]  
            i += 1  
        else:  
            temp[k] = a[j]  
            j += 1  
    k += 1
```


MergeSort – slévání – závěr

```
# na konec připojí zbylé prvky
# z levého / pravého běhu
while i <= stred:
    temp[k] = a[i]
    i, k = i+1, k+1
while j <= konec:
    temp[k] = a[j]
    j, k = j+1, k+1

# výsledek zkopíruje do pole a
a[zacatek:konec+1] =
    temp[zacatek:konec+1]
```

MergeSort – třídění

```
def mergeSort(a):  
    n = len(a)    # délka vstupního pole  
    temp = [None] * n # alokuje pomocné  
  
    # slévá sousední běhy délek 1,2,4,...  
    beh = 1  
    while beh < n:  
        for zacatek in range(0, n-beh, 2*beh):  
            stred = zacatek + beh - 1  
            konec = min(stred + beh, n-1)  
            merge(a, temp, zacatek, stred, konec)  
        beh *= 2
```

Problém

① Vylepšete implementaci algoritmu **MergeSort** tak, abyste se na konci funkce **Merge** vyhnuli kopírování z pomocného pole **temp** zpět do vstupního pole **a**

a[zacatek:konec+1] = **temp**[zacatek:konec+1]

② Rozmyslete si, jak by šel algoritmus **MergeSort** využít pro setřídění spojových seznamů.

Půjde to snáze rekurzí nebo iterací?

Aplikace: Vnější třídění

Problém

- setřídít data, která se nevejdou do RAM

Nové kritérium

- minimalizovat I/O operace

Idea

- slévání běhů
- běh uložen v souboru
- fáze rozdělování, fáze slévání

Přímé slučování

Na začátku

- tříděná data v jednu souboru (triviální běhy délky 1)

Fáze rozdělávání

- setříděné běhy ze vstupního souboru rozdělujeme
- střídavě do dvou pomocných souborů S1 a S2

Fáze slévání

- nejprve sloučíme první běhy z S1 a S2 do běhu
- o dvojnásobné délce, zapíšeme do výstupního souboru
- stejně pro druhé běhy
- takto sloučením S1 a S2 vytvoříme jeden soubor
- tvořený běhy o dvojnásobné délce

Přímé slučování

Složitost

- chceme minimalizovat počet operací se soubory
- $\# \text{ read} = \# \text{ write}$
- $2n \lceil \log_2 n \rceil$

Vylepšení

- sloučit rozdělování + slévání
- slévat více běhů
- využít přirozeně setříděných částí vstupu
- předtřídit počáteční běhy v RAM

Jednofázové slučování

👉 **Idea:** sloučit rozdělávání + slévání

- rozdělávání do 2 souborů jen na začátku
- dále: 2 fáze \rightarrow 1 fáze

Nové běhy hned rozdělujeme

- střídavě do dvou souborů

Počet operací

- $\# \text{ read} \approx n \log_2 n$

Zvýšení stupně slučování

👉 **Idea:** k -cestné slučování

- rozdělujeme k běhů do k souborů

Počet kroků p

- $k^{p-1} < n \leq k^p$
- $p = \lceil \log_k n \rceil$
- zrychlení $\log_2 n / \log_k n = \log_2 k$

✓ Jak vybrat minimum z k běhů?

- halda: čas $O(\log k)$

✗ Počet otevřených souborů

- 2fázové: $k + 1$ soubor
- 1fázové: $2k$ souborů (k vstupních a k výstupních)

Přirozené slučování

👉 **Idea:** využít již setříděné úseky na vstupu

- některé úseky vstupu mohou být již setříděny
- proč toho nevyužít?

Počáteční běhy

- již setříděné úseky vstupu
- délka běhu ≥ 1

Počet kroků

- počet počátečních běhů b
- počet kroků $\log_2 n \rightarrow \log_2 b$

Časová složitost

- $O(n \log b)$

Předtřídit počáteční běhy

👉 **Idea:** předtřídit počáteční běhy v RAM

- lze spojit s rozdělovací fází 1.kroku
- # read / write se nezvýší

Časová složitost

- m = délka přetříděného běhu
- počet běhů $\lceil n/m \rceil$
- celkový čas $O(n \log(n/m))$

MergeSort – další variace

TimSort

- Tim Peters (2002), využívá Python od verze 2.3
- stabilní hybridní třídící algoritmus
- metoda: Peter McIlroy, SODA 1993
- délka běhu $b \in \langle 32, 64 \rangle$ tak, aby n/b byla mocnina 2
- běhy jsou setříděny vkládáním ([InsertionSort](#))
- slévání běhů ([MergeSort](#))

Třídění rozdělováním – QuickSort

☀ Idea

- pole délky ≤ 1 je již setříděno
- jinak ve vstupním poli zvolíme prvek zvaný **pivot**
- prvky v poli přeskupíme tak, aby výsledné pole tvořily dva navazující úseky
 - » levý s prvky \leq **pivot**
 - » pravý s prvky \geq **pivot**
- oba úseky setřídíme rekurzivně

QuickSort – Partition

```
def quickSort(a, start, stop):  
    """ setřídí a[start..stop] """  
    levy, pravy = start, stop # ukazatele  
    pivot = a[(levy+pravy)//2]  
    while levy <= pravy: # nepřeskočily se  
        while a[levy] < pivot: # patří vlevo  
            levy += 1 # posouvat levý ukazatel  
        while pivot < a[pravy]: # patří vpravo  
            pravy -= 1 # posouvat pravý ukazatel  
    # pokračuje →
```

QuickSort – Partition

```
if levy < pravy: # nesetkaly se
    # vyměň hodnoty
    a[levy], a[pravy] = a[pravy], a[levy]
if levy <= pravy: # nepřeskočily se
    # pokračuj
    levy, pravy = levy + 1, pravy - 1
# konec while-cyklu
```

QuickSort – rekurze

```
# netriviální úseky setříd' rekurzivně  
if start < pravy:  
    quickSort(a, start, pravy)  
if levy < stop:  
    quickSort(a, levy, stop)
```


QuickSort – časová složitost

Časová složitost $T(n)$ v **nejhorším případě**

- $T(n) = O(n) + \max_{1 \leq i \leq n-1} (T(i) + T(n-i))$

Horní odhad

- pomocí stromu rekurze
- na každé hladině: čas $O(n)$
- počet hladin $\leq n$
- $T(n) = O(n^2)$



Dolní odhad

- $T(n) \geq \Omega(n) + T(n-1) = \Omega(n^2)$



pro jaké vstupy nastane?

QuickSort – časová složitost

Časová složitost v **nejlepším** případě

- co když se podaří v každém kroku zvolit jako pivotový prvek **medián** ?
- $T(n) = O(n) + 2 T(n/2)$
- výška stromu rekurze logaritmická
- čas $O(n \cdot \log n)$

Časová složitost v **průměrném** případě $O(n \cdot \log n)$

- důkaz : ADS I

QuickSort – zrychlení

Volba pivotového prvku

- určení mediánu v čase $O(n)$ \Rightarrow teoretické zrychlení na čas $O(n \cdot \log n)$ i v nejhorším případě

Volba pivota v praxi

- náhodně
- medián z $a[1]$, $a[n/2]$, $a[n-1]$
- medián ze 3 náhodně zvolených

Odstranění konce rekurze

- malé $n \Rightarrow$ setřídít přímou metodou (InsertionSort)

QuickSort bez rekurze

Rekuzivní volání \Rightarrow

- uložení hranic úseku k setřídění do zásobníku
- simulace průchodu stromem rekurze

✓ Může být úspornější

- časově (obsluha rekurze)
- i prostorově (stačí zásobník logaritmické velikosti)

✗ Složitější kód

QuickSort – prostorová složitost

Netřídí na místě !

K obsluze rekurze je třeba zásobník

- prostorová složitost $O(n)$
- lze zlepšit na $O(\log n)$

 Jaké úseky budeme ukládat na zásobník, aby nám stačil prostor $O(\log n)$?

Problémy: QuickSort

③ Prvek posloupnosti délky n nazveme **skoromediánem**, pokud leží v uspořádané posloupnosti na k -tém místě, kde

$$n/4 \leq k \leq 3n/4 .$$

Kdyby se nám v algoritmu QuickSort podařilo v každém kroku vybrat v čase $O(1)$ jako pivota skoromedián, změnilo by to nějak časovou složitost v nejhorším případě?

Ve vaší analýze složitosti můžete předpokládat, že prvky na vstupu jsou po dvou různé.

Problémy: QuickSort

④ Upravte QuickSort tak, aby pro

- zadané pole a
- a číslo k

vrátil k -tý nejmenší prvek a bez toho, že by pole třídil.
Mělo by k tomu stačit jediné rekurzivní volání.

Časová složitost výsledného algoritmu je v nejhorším případě stále kvadratická, dá se ale ukázat, že v průměrném případě pracuje v lineárním čase.